



Sistema de recomendación para retail aumentado por transfer learning

Autor:

Lic. Matías Agustín Souto

Director:

A definir (A definir)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 25 de agosto de 2026 y el 13 de octubre de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar	5
2. Identificación y análisis de los interesados	6
3. Propósito del proyecto	7
4. Alcance del proyecto	7
5. Supuestos del proyecto.	8
6. Product Backlog	8
7. Criterios de aceptación de historias de usuario	9
8. Fases de CRISP-DM	11
9. Desglose del trabajo en tareas	11
10. Planificación de Sprints	14
11. Diagrama de Gantt (sprints)	20
12. Gobernanza de datos	21
12.1 Cumplimiento normativo	21
12.2 Ética en el uso de inteligencia artificial	21
13. Gestión de riesgos	22
14. Sprint Review	23
15. Sprint Retrospective	24

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	25 de agosto de 2026
1	Se completa hasta el punto 5 inclusive	6 de septiembre de 2026
2	Se completa hasta el punto 9 inclusive	13 de septiembre de 2026

Acta de constitución del proyecto

Buenos Aires, 25 de agosto de 2026

Por medio de la presente se acuerda con el Lic. Matías Agustín Souto que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Sistema de recomendación para retail aumentado por transfer learning” y consistirá en la implementación del prototipo de un sistema de recomendación para compras online con miras a embeberlo en un flujo conversacional. El trabajo tendrá un presupuesto preliminar estimado de 600 horas y un costo, con fecha de inicio el 25 de agosto de 2026 y fecha de presentación pública en Abril de 2027.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Equipo de IA Conversacional
NTT Data

A definir
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El presente proyecto constituye una iniciativa personal del alumno, orientada a su propio crecimiento profesional dentro del área de inteligencia artificial conversacional. El autor se desempeña actualmente como ingeniero conversacional en NTT Data, una empresa de consultoría tecnológica y de telecomunicaciones, en la que se exploran diversas experiencias de compra conversacional que buscan replicar, dentro de una aplicación, la naturalidad de una interacción cara a cara en un comercio: el usuario inicia una sesión con un agente de voz o texto y solicita productos con la misma naturalidad con la que se lo pediría a una persona en una tienda. No se cuenta con financiamiento externo ni con acuerdos de confidencialidad o de propiedad intelectual asociados a este trabajo, ya que se trata de un desarrollo autónomo cuyos resultados son de autoría del alumno.

En el estado actual de la industria, se observa que la mayoría de las soluciones conversacionales para retail se limitan a actuar como buscadores de productos. En algunos casos llegan a incorporar un componente agéntico acotado (por ejemplo, agregar al carrito el producto ya identificado por el usuario). Sin embargo, estas soluciones no suelen incorporar un motor de recomendación robusto que profile al usuario y proponga proactivamente productos relevantes dentro del propio flujo conversacional, tal como lo haría un vendedor humano que reconoce a un cliente recurrente y anticipa sus preferencias.

El problema que se busca atender con este proyecto es, entonces, la falta de un componente de perfilado y recomendación que sea a la vez robusto y agnóstico a la plataforma conversacional que lo consume. La solución propuesta consiste en desarrollar un pipeline de perfilamiento-recomendación pensado como un servicio desacoplado del agente conversacional, expuesto a este último mediante una interfaz de herramientas llamables por el agente (*tools*) simple. Por ejemplo, `get_profile(user)` y `recommend(context)`. De esta forma, el mismo motor podría integrarse tanto a una experiencia de “compra sin clicks” completamente conversacional como a una aplicación de retail clásica, ya que las recomendaciones no dependen de cómo el usuario efectúa la compra sino de su perfil y comportamiento.

El motor por desarrollar se compone de dos módulos. El primero es un perfilador que clasifica a los usuarios en función de features RFM (Recencia, Frecuencia, Valor monetario) y de atributos de comportamiento adicionales. El segundo módulo del motor es un recomendador híbrido, que combina señales colaborativas, de contenido y de co-compra, y que produce un ranking de ítems a partir del perfil generado por el primer módulo. Un aspecto distintivo de la propuesta es que se aborda el recomendador como un problema de transfer learning: se entrena un modelo “pre entrenado” sobre un dataset extenso y público (Amazon Reviews’23) que permite acotar el universo de productos y perfiles a un conjunto de características y probabilidades de recomendación. Luego, se ajusta un modelo “dedicado”, derivado del anterior, sobre el conjunto de datos disponible para un caso de uso concreto, típicamente más escueto en volumen o en riqueza de atributos. La ganancia esperada de este enfoque es poder producir recomendaciones de mejor calidad con menos datos y menor costo de cómputo que si se entrenara un modelo desde cero para cada nuevo dominio.

En la figura 1 se presenta el diagrama en bloques del sistema. Se observa que el flujo conversacional queda contenido en un agente orquestador (para la prueba de concepto, una API simple sobre Claude), que interpreta el lenguaje natural del usuario y llama al pipeline de perfilado-recomendación a través de un contrato de interfaz estable. El “motor” agrupa al perfilador y al recomendador, cuyos resultados se persisten estado respecto de la conversación en curso (*stateful*). Como capa de persistencia se propone PostgreSQL, dada su capacidad

de almacenar tanto datos estructurados (reseñas, perfiles de usuario) como semiestructurados (metadata de ítems en formato JSONB, tabla de co-compra).




Figura 1. Diagrama del sistema.

El alcance de este trabajo se acota al diseño e implementación del sistema de perfilado-recomendación y de su API, sin abarcar el desarrollo del flujo conversacional completo. No obstante, se construirá una prueba de concepto que demuestre cómo un agente conversacional podría consumir dicha API en tiempo real. Entre los desafíos identificados a priori se destacan: el sesgo introducido por utilizar reseñas como proxy de compra (solo se observa al usuario cuando dejó una reseña), el problema de cold-start para usuarios e ítems nuevos, y la cobertura incompleta de metadata en parte del dataset, que se resolverá filtrando o marcando los ítems afectados según la estrategia de splitting estándar del dataset.

Se trata de un desarrollo desde cero que se llevará hasta el nivel de prueba de concepto. La innovación radica principalmente en el enfoque de transfer learning aplicado a la combinación perfilado-recomendación y en el diseño de una interfaz agnóstica al bot conversacional, lo que habilita su reutilización en distintos verticales de comercio.

2. Identificación y análisis de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Cliente	Equipo de IA Conversacional	NTT Data	Referente de producto
Responsable	Lic. Matías Agustín Souto	FIUBA	Alumno
Orientador	<i>A definir</i>	<i>A definir</i>	Director del Trabajo Final
Usuario final	-	-	Consumidor de retail que compra vía canal conversacional

A continuación se detallan las principales características de cada interesado:

- Cliente: Equipo de IA Conversacional. Ofrece soluciones de compra conversacional a sus propios clientes. En este caso, de retail. Este interesado valora que el motor de perfilado-recomendación sea agnóstico al bot conversacional y a la vertical de comercio, de forma de poder reutilizarlo en distintas implementaciones para sus clientes.
- Responsable: el propio alumno, cursante de la Carrera de Especialización en Inteligencia Artificial de FIUBA, a cargo de la totalidad del diseño, desarrollo y documentación del proyecto.
- Orientador: a definir. Todavía no se encuentra asignado un director de Trabajo Final.
- Usuario final: es un consumidor genérico de una tienda de retail que interactúa con el agente conversacional para buscar y comprar productos. No se ha caracterizado un segmento específico de usuario, ya que el sistema está pensado para ser agnóstico al vertical de comercio.

3. Propósito del proyecto

Diseñar e implementar un sistema de perfilado y recomendación para retail, basado en un enfoque de transfer learning, que pueda integrarse como herramienta de un agente conversacional de compras. Se busca que el sistema profile a los usuarios a partir de features RFM y de comportamiento, y que genere recomendaciones híbridas de productos con una calidad aceptable incluso contando con pocos datos propios del cliente que lo adopte, aprovechando el conocimiento transferido desde un modelo pre entrenado sobre un dataset público y extenso. Se trata de una prueba de concepto con la que se pretende demostrar que es posible desacoplar la inteligencia de recomendación del canal conversacional específico. Este enfoque habilita su reutilización entre distintos bots y verticales de comercio. De esta manera, se espera avanzar en el desarrollo profesional del alumno dentro del área de inteligencia artificial conversacional.

4. Alcance del proyecto

El proyecto incluye:

- Diseño e implementación del módulo perfilador, basado en features RFM y atributos de comportamiento.
- Diseño e implementación del módulo recomendador híbrido (colaborativo + contenido + co-compra).
- Entrenamiento de un modelo pre entrenado sobre el dataset Amazon Reviews'23.
- Búsqueda y selección de un dataset más acotado, todavía no identificado, sobre el que ajustar un modelo “dedicado” vía transfer learning, para validar la hipótesis de mejores recomendaciones con menos datos.
- Exposición de los resultados vía una API con contrato estable (por ejemplo `get_profile`, `recommend`).
- Diseño del esquema de persistencia en PostgreSQL (reviews, perfiles de usuario, ítems, co-compra).

- Una prueba de concepto de un agente conversacional simple que se monte sobre la API sobre Claude para denotar el punta a punta.

El presente proyecto no incluye:

- El desarrollo del flujo conversacional completo ni de la interfaz de usuario final. Es decir, no es un desarrollo que se proponga entregar una solución conversacional punta a punta cerrada.
- La integración con un bot conversacional real de producción. Tampoco espera ser conectada a un bot específico.
- El despliegue en infraestructura productiva ni la operación continua del sistema.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- El dataset Amazon Reviews'23 es suficientemente representativo del comportamiento de compra como para entrenar un modelo pre entrenado útil, a pesar de estar compuesto por reseñas y no por transacciones directas.
- Que va a ser posible encontrar o construir un dataset más acotado, con menor volumen o riqueza de atributos, adecuado para validar el enfoque de transfer learning.
- Que la infraestructura de cómputo personal (o de bajo costo) disponible es suficiente para entrenar los modelos propuestos dentro de los plazos del proyecto.
- Que no van a existir cambios significativos en la disponibilidad o el formato del dataset público durante el desarrollo del proyecto.

6. Product Backlog

El Product Backlog se organiza en cuatro épicas, cada una con dos historias de usuario. El criterio para la asignación de story points fue la escala Fibonacci (1-2-3-5-8-13). Por lo tanto, solo se podrán asignar esos valores. Se pondera la complejidad técnica, el nivel de incertidumbre y la experiencia previa del alumno.

- **Épica 1 — Perfilado de usuarios**

- **HU1** (Prioridad: alta, 8 SP): como responsable del proyecto, quiero calcular las variables RFM (recencia, frecuencia, valor monetario) de cada usuario a partir de sus reseñas para poder clasificarlo según su comportamiento de consumo.
- **HU2** (Prioridad: media, 5 SP): como responsable del proyecto, quiero enriquecer el perfil RFM con atributos de comportamiento adicionales. Por ejemplo, categorías más frecuentes, o recencia por categoría para mejorar la calidad de la segmentación.

- **Épica 2 — Motor de recomendación híbrido**

- **HU3** (Prioridad: alta, 13 SP): como agente conversacional, quiero recibir un ranking de ítems que combine señales colaborativas, de contenido y de co-compra, para poder ofrecer recomendaciones más relevantes que con un solo enfoque aislado.
- **HU4** (Prioridad: media, 5 SP): como agente conversacional, quiero recibir un score de confianza junto con cada recomendación, para poder decidir cuándo mostrarla u ofrecer alternativas.

■ Épica 3 — Transfer learning entre modelos

- **HU5** (Prioridad: alta, 13 SP): como responsable del proyecto, quiero entrenar un modelo sobre el dataset Amazon Reviews'23 para contar con una base amplia de productos y perfiles de usuario.
- **HU6** (Prioridad: alta, 13 SP): como responsable del proyecto, quiero ajustar un modelo dedicado a partir del pre entrenado sobre un dataset más acotado para validar que se pueden lograr buenas recomendaciones con menos datos.

■ Épica 4 — Exposición vía API y prueba de concepto

- **HU7** (Prioridad: alta, 8 SP): como agente conversacional, quiero consultar `get_profile(user)` y `recommend(context)` a través de un contrato de API estable para poder recomendar productos sin conocer el detalle interno del motor.
- **HU8** (Prioridad: media, 8 SP): como usuario final, quiero recibir recomendaciones de productos dentro de una conversación de compra simulada para validar que el sistema funciona de punta a punta.

7. Criterios de aceptación de historias de usuario

■ Épica 1

• HU1:

- (a) para todo usuario con al menos una reseña, se calculan recencia, frecuencia y valor monetario sin valores nulos.
- (b) los tres valores se normalizan en una escala común y el cálculo es reproducible ante los mismos datos de entrada.
- (c) el usuario queda asignado a un segmento RFM discreto y documentado. Por ejemplo, “cliente valioso”, “cliente en riesgo” o “cliente nuevo”.

El criterio de éxito será que al menos el 80 % de los usuarios con reseñas registradas queda correctamente segmentado, sin valores nulos ni indefinidos.

• HU2:

- (a) el perfil incluye al menos dos atributos de comportamiento adicionales a RFM.
- (b) dichos atributos no duplican información ya cubierta por RFM.
- (c) se documenta el criterio de selección y el rango de valores esperado de cada atributo.

El criterio de éxito será que los atributos adicionales mejoren la separación entre segmentos respecto de usar solo RFM. Por ejemplo, mayor distancia o cohesión entre clústers.

■ Épica 2

- **HU3:**

- (a) dado un perfil de usuario, se devuelve un ranking de al menos N ítems combinando las tres señales.
- (b) cada ítem recomendado incluye la traza de qué señal(es) contribuyeron a su score.
- (c) el ranking no repite ítems ya comprados o reseñados por el usuario, salvo que se solicite explícitamente.

El criterio de éxito será que el ranking híbrido obtenga una métrica de calidad superior a la de cualquiera de las tres señales evaluadas de forma aislada. Por ejemplo, mejor precisión de clasificación (precision@10) o mejor NDCG@10.

- **HU4:**

- (a) cada recomendación devuelta incluye un score de confianza numérico en un rango definido. Un buen rango es $[0, 1]$ ya que está normalizado y facilita comparar recomendaciones entre sí.
- (b) el score decrece de forma consistente ante menor evidencia disponible, como sería en el caso de un usuario nuevo.
- (c) existe un umbral configurable por debajo del que la recomendación puede omitirse.

El criterio de éxito será que aplicar el umbral de confianza reduzca la proporción de recomendaciones de baja relevancia sin descartar más del 20 % de las recomendaciones totales.

- **Épica 3**

- **HU5:**

- (a) se documenta la muestra de Amazon Reviews'23 utilizada (tamaño, categorías, período).
- (b) se reporta al menos una métrica de calidad sobre un conjunto de validación.
- (c) el modelo y sus artefactos (pesos, features) quedan versionados y son reutilizables por el modelo dedicado.

El criterio de éxito será que el modelo pre entrenado supere a un baseline aleatorio o de popularidad en la métrica de calidad reportada sobre el conjunto de validación.

- **HU6:**

- (a) se declara explícitamente el dataset acotado utilizado para el ajuste.
- (b) se compara al menos una métrica de calidad entre el modelo dedicado y una alternativa entrenada desde cero.
- (c) el proceso de ajuste es reproducible sobre el mismo dataset acotado.

El criterio de éxito será que el modelo dedicado iguale o supere la métrica de calidad del modelo entrenado desde cero, usando el mismo dataset acotado, lo que validaría la ganancia del transfer learning.

- **Épica 4**

- **HU7:**

- (a) `get_profile(user)` responde en un formato de contrato documentado.
- (b) `recommend(context)` responde un ranking en formato documentado dentro de un tiempo inferior a 2 segundos en la prueba de concepto.
- (c) ambos contratos se mantienen estables ante cambios internos del motor, y se versionan si cambian.

El criterio de éxito será que el 100 % de las pruebas realizadas completen el ciclo `get_profile` → `recommend` sin errores y dentro del tiempo de respuesta acotado.

- **HU8:**

- (a) un usuario simulado recibe al menos una recomendación dentro de una conversación con el agente.
- (b) el flujo de punta a punta queda documentado con al menos un ejemplo registrado.
- (c) se documentan al menos dos casos límite, como un usuario nuevo o un ítem sin metadata, y cómo los maneja la prueba de concepto.

El criterio de éxito será que al menos una conversación simulada de punta a punta concluya con una recomendación mostrada al usuario, incluyendo el manejo correcto de los casos límite documentados.

8. Fases de CRISP-DM

1. **Comprensión del negocio:** el objetivo es perfilar usuarios y generar recomendaciones híbridas relevantes dentro de un flujo conversacional de retail. El valor agregado de la IA es habilitar una experiencia de vendedor proactivo. Las métricas de éxito son la calidad de las recomendaciones y evidencia de que el modelo dedicado supera a uno entrenado desde cero con menos datos.
2. **Comprensión de los datos:** el dataset principal es Amazon Reviews'23, que contiene reseñas, calificaciones y metadata de productos. Se releva su volumen, cobertura de metadata y el sesgo propio de basarse en reseñas, ya que solo se observa al usuario que dejó reseña.
3. **Preparación de los datos:** construcción de las features RFM por usuario, filtrado o marcado de ítems con metadata incompleta, y diseño del esquema de persistencia en PostgreSQL, que incluye reviews, perfiles, ítems en formato JSONB y una tabla de co-compra.
4. **Modelado:** el modelado se aborda como un problema híbrido, combinando perfilado mediante segmentación RFM y recomendación mediante enfoques colaborativo, de contenido y de co-compra. Además, se aplicará transfer learning entre un modelo pre entrenado sobre un dataset extenso y un modelo dedicado ajustado sobre un dataset acotado.
5. **Evaluación del modelo:** se medirá la calidad de los rankings de recomendación y de la segmentación RFM, comparando el modelo dedicado contra una versión entrenada desde cero para validar la ganancia del transfer learning.
6. **Despliegue del modelo:** para esta prueba de concepto, el despliegue se limita a exponer el motor vía una API simple consumida por un agente conversacional de prueba (API sobre Claude), sin publicación en infraestructura productiva.

9. Desglose del trabajo en tareas

A partir de las historias de usuario definidas en la sección 6, se descompone el trabajo en tareas técnicas concretas y acotadas en el tiempo. El criterio de estimación considera la complejidad técnica, el nivel de incertidumbre, como la disponibilidad de un dataset acotado para el modelo

dedicado, y la experiencia previa del alumno. La prioridad de cada tarea depende de su relevancia funcional y de si resulta bloqueante para otras tareas.

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU1	Realizar un análisis exploratorio de datos (EDA) sobre las reseñas del dataset, para entender distribución, calidad y cobertura por usuario	4 h	Alta
HU1	Extraer y limpiar la fecha de reseña, el rating o monto, y el producto de cada reseña por usuario	4 h	Alta
HU1	Calcular recencia y frecuencia por usuario	3 h	Alta
HU1	Calcular valor monetario (o proxy, dado que el dataset son reseñas) por usuario	3 h	Alta
HU1	Detectar y tratar outliers en las variables RFM (usuarios con actividad atípica)	4 h	Media
HU1	Normalizar las tres variables en una escala común y validar reproducibilidad	3 h	Alta
HU1	Definir umbrales/quantiles de segmentación RFM y documentar los segmentos resultantes	4 h	Alta
HU2	Explorar candidatos de atributos de comportamiento adicionales, como categorías frecuentes, recencia por categoría y diversidad de compra	3 h	Media
HU2	Diseñar el modelo de datos (esquema) del objeto “perfil de usuario”, integrando las variables RFM y los atributos seleccionados	4 h	Alta
HU2	Calcular los atributos seleccionados por usuario	4 h	Media
HU2	Validar, mediante un análisis de correlación y redundancia, que los nuevos atributos no dupliquen información ya cubierta por RFM	3 h	Media
HU2	Integrar los atributos calculados en el objeto perfil de usuario y documentar su rango esperado	3 h	Media
HU3	Realizar un EDA de ítems y de interacciones (compras/co-compra) para dimensionar sparsity y cobertura de metadata	4 h	Alta
HU3	Diseñar el esquema de salida del recomendador (ranking, score, señales que contribuyeron a cada ítem)	3 h	Alta
HU3	Explorar y entrenar un modelo de filtrado colaborativo que aprenda afinidades usuario-ítem a partir del historial de reseñas	8 h	Alta
HU3	Construir una señal de contenido, buscando ítems similares entre sí a partir de su categoría, sus atributos y su descripción	8 h	Alta
HU3	Construir una señal de co-compra, identificando qué ítems suelen comprarse juntos a partir de la tabla de co-compra	6 h	Alta
HU3	Diseñar y entrenar un modelo dedicado (ranker) que combine las tres señales en un único score de recomendación	8 h	Alta

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU3	Filtrar del ranking final los ítems ya comprados/reseñados por el usuario, salvo pedido explícito	2 h	Media
HU4	Definir qué señales de evidencia disponible se usan para estimar la confianza, como la cantidad de señales activas, la cobertura de datos o el cold-start	3 h	Media
HU4	Diseñar la fórmula o heurística de score de confianza en función de esas señales	3 h	Media
HU4	Implementar el cálculo del score y exponerlo junto con cada recomendación	3 h	Media
HU4	Definir y calibrar un umbral configurable por debajo del que la recomendación se omite o se reemplaza por un fallback	4 h	Media
HU5	Consolidar el perfilador (HU1/HU2) y el recomendador híbrido (HU3/HU4), entrenados sobre Amazon Reviews'23, como un único artefacto "modelo pre entrenado"	4 h	Alta
HU5	Evaluar el modelo pre entrenado de punta a punta (perfilado + recomendación) con una métrica de calidad sobre un conjunto de validación	5 h	Alta
HU5	Versionar y persistir los artefactos del modelo pre entrenado para que el modelo dedicado (HU6) pueda reutilizarlos	3 h	Media
HU6	Identificar o construir un dataset más acotado, con menor volumen o riqueza de atributos, adecuado para el ajuste	6 h	Alta
HU6	Definir el alcance del modelo dedicado: qué componentes del pre entrenado se reutilizan y cuáles se reentrenan/ajustan	4 h	Alta
HU6	Ajustar el modelo dedicado a partir del pre entrenado (fine-tuning / transfer learning) sobre el dataset acotado	8 h	Alta
HU6	Entrenar un modelo de referencia desde cero sobre el mismo dataset acotado, para tener con qué comparar	6 h	Alta
HU6	Comparar las métricas de calidad entre el modelo dedicado y el modelo entrenado desde cero, y documentar la diferencia	4 h	Alta
HU6	Validar que el proceso de ajuste es reproducible sobre el mismo dataset acotado	3 h	Media
HU7	Diseñar y documentar el contrato de <code>get_profile(user)</code> (esquema de entrada/salida)	3 h	Alta
HU7	Diseñar y documentar el contrato de <code>recommend(context)</code> (esquema de entrada/salida)	3 h	Alta
HU7	Implementar el endpoint <code>get_profile(user)</code> sobre el perfilador	4 h	Alta
HU7	Implementar el endpoint <code>recommend(context)</code> sobre el recomendador	4 h	Alta

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU7	Definir una estrategia de versionado del contrato ante cambios internos del motor	3 h	Media
HU7	Probar ambos endpoints de punta a punta, midiendo tiempos de respuesta y formatos, y documentar los resultados	3 h	Alta
HU8	Diseñar el flujo conversacional básico de la prueba de concepto, que incluye saludo, búsqueda, recomendación y cierre	3 h	Media
HU8	Implementar el agente orquestador sobre la API de Claude, con las tools <code>get_profile/recommend</code> definidas	6 h	Media
HU8	Integrar el agente con la API del motor (llamadas reales a <code>get_profile/recommend</code>)	4 h	Media
HU8	Definir escenarios de prueba simulados que cubran un usuario recurrente, un usuario nuevo o cold-start, y un ítem sin metadata	3 h	Media
HU8	Ejecutar y registrar al menos un ejemplo de conversación de punta a punta (log o transcripción)	2 h	Media
HU8	Documentar cómo la prueba de concepto maneja los casos límite identificados	2 h	Media

Cuadro 1. Desglose de tareas por historia de usuario. Total estimado: 177 h.

10. Planificación de Sprints

La carga horaria total del proyecto se estima en 600 horas. Las tareas técnicas definidas en la sección 9 suman 177 horas. Para cubrir la incertidumbre propia de un trabajo individual y de un dominio que el alumno explora por primera vez, esa estimación se duplicó al planificar los sprints, lo que da 354 horas técnicas. Las 246 horas restantes se destinan a tareas no técnicas, como la planificación, la redacción de la memoria, el seguimiento con el tutor, la preparación de la defensa y una reserva de contingencia.

El Sprint 0 corresponde a la planificación y se extiende desde el inicio de la cursada hasta la entrega del plan. Los Sprints 1 a 10 duran dos semanas cada uno y concentran entre 50 y 55 horas efectivas. Al ser un proyecto individual, el responsable de todas las tareas es el propio alumno. El porcentaje de avance se actualizará en cada revisión.

Sprint	HU o fase	Tarea	Horas	Responsable	Avance
Sprint 0	Planificación	Definir alcance y cronograma	15 h	Alumno	0 %
Sprint 0	Planificación	Redactar el plan de proyecto	30 h	Alumno	0 %
Sprint 0	Planificación	Reunión con el tutor y el cliente	5 h	Alumno	0 %
Sprint 0	Planificación	Ajuste de los entregables	10 h	Alumno	0 %

Sprint	HU o fase	Tarea	Horas	Responsable	Avance
Sprint 1	HU1	Realizar un análisis exploratorio de datos (EDA) sobre las reseñas del dataset, para entender distribución, calidad y cobertura por usuario	8 h	Alumno	0 %
Sprint 1	HU1	Extraer y limpiar la fecha de reseña, el rating o monto, y el producto de cada reseña por usuario	8 h	Alumno	0 %
Sprint 1	HU1	Calcular recencia y frecuencia por usuario	6 h	Alumno	0 %
Sprint 1	HU1	Calcular valor monetario (o proxy, dado que el dataset son reseñas) por usuario	6 h	Alumno	0 %
Sprint 1	HU2	Explorar candidatos de atributos de comportamiento adicionales, como categorías frecuentes, recencia por categoría y diversidad de compra	6 h	Alumno	0 %
Sprint 1	Documentación	Redactar la introducción y el contexto de la memoria	16 h	Alumno	0 %
Sprint 1	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %
Sprint 2	HU1	Detectar y tratar outliers en las variables RFM (usuarios con actividad atípica)	8 h	Alumno	0 %
Sprint 2	HU1	Normalizar las tres variables en una escala común y validar reproducibilidad	6 h	Alumno	0 %
Sprint 2	HU1	Definir umbrales/quantiles de segmentación RFM y documentar los segmentos resultantes	8 h	Alumno	0 %
Sprint 2	HU2	Diseñar el modelo de datos (esquema) del objeto “perfil de usuario”, integrando las variables RFM y los atributos seleccionados	8 h	Alumno	0 %
Sprint 2	HU2	Calcular los atributos seleccionados por usuario	8 h	Alumno	0 %
Sprint 2	Documentación	Redactar el capítulo de datos y perfilado RFM	12 h	Alumno	0 %
Sprint 2	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %

Sprint	HU o fase	Tarea	Horas	Responsable	Avance
Sprint 3	HU2	Validar, mediante un análisis de correlación y redundancia, que los nuevos atributos no dupliquen información ya cubierta por RFM	6 h	Alumno	0 %
Sprint 3	HU2	Integrar los atributos calculados en el objeto perfil de usuario y documentar su rango esperado	6 h	Alumno	0 %
Sprint 3	HU3	Realizar un EDA de ítems y de interacciones (compras/co-compra) para dimensionar sparsity y cobertura de metadata	8 h	Alumno	0 %
Sprint 3	HU3	Diseñar el esquema de salida del recomendador (ranking, score, señales que contribuyeron a cada ítem)	6 h	Alumno	0 %
Sprint 3	HU3	Filtrar del ranking final los ítems ya comprados/reseñados por el usuario, salvo pedido explícito	4 h	Alumno	0 %
Sprint 3	Documentación	Redactar el capítulo de perfilado de usuarios	12 h	Alumno	0 %
Sprint 3	Contingencia	Buffer para desvíos del sprint	8 h	Alumno	0 %
Sprint 3	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %
Sprint 4	HU3	Explorar y entrenar un modelo de filtrado colaborativo que aprenda afinidades usuario-ítem a partir del historial de reseñas	16 h	Alumno	0 %
Sprint 4	HU3	Construir una señal de contenido, buscando ítems similares entre sí a partir de su categoría, sus atributos y su descripción	16 h	Alumno	0 %
Sprint 4	Documentación	Documentar técnicamente las señales del recomendador	10 h	Alumno	0 %
Sprint 4	Contingencia	Buffer para desvíos del sprint	8 h	Alumno	0 %
Sprint 4	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %
Sprint 5	HU3	Construir una señal de co-compra, identificando qué ítems suelen comprarse juntos a partir de la tabla de co-compra	12 h	Alumno	0 %

Sprint	HU o fase	Tarea	Horas	Responsable	Avance
Sprint 5	HU3	Diseñar y entrenar un modelo dedicado (ranker) que combine las tres señales en un único score de recomendación	16 h	Alumno	0 %
Sprint 5	HU4	Definir qué señales de evidencia disponible se usan para estimar la confianza, como la cantidad de señales activas, la cobertura de datos o el cold-start	6 h	Alumno	0 %
Sprint 5	Documentación	Redactar el capítulo del recomendador híbrido	16 h	Alumno	0 %
Sprint 5	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %
Sprint 6	HU4	Diseñar la fórmula o heurística de score de confianza en función de esas señales	6 h	Alumno	0 %
Sprint 6	HU4	Implementar el cálculo del score y exponerlo junto con cada recomendación	6 h	Alumno	0 %
Sprint 6	HU4	Definir y calibrar un umbral configurable por debajo del que la recomendación se omite o se reemplaza por un fallback	8 h	Alumno	0 %
Sprint 6	HU5	Consolidar el perfilador (HU1/HU2) y el recomendador híbrido (HU3/HU4), entrenados sobre Amazon Reviews'23, como un único artefacto "modelo pre entrenado"	8 h	Alumno	0 %
Sprint 6	HU5	Evaluar el modelo pre entrenado de punta a punta (perfilado + recomendación) con una métrica de calidad sobre un conjunto de validación	10 h	Alumno	0 %
Sprint 6	Documentación	Documentar el pre entrenamiento y su evaluación	12 h	Alumno	0 %
Sprint 6	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %
Sprint 7	HU5	Versionar y persistir los artefactos del modelo pre entrenado para que el modelo dedicado (HU6) pueda reutilizarlos	6 h	Alumno	0 %

Sprint	HU o fase	Tarea	Horas	Responsable	Avance
Sprint 7	HU6	Identificar o construir un dataset más acotado, con menor volumen o riqueza de atributos, adecuado para el ajuste	12 h	Alumno	0 %
Sprint 7	HU6	Definir el alcance del modelo dedicado: qué componentes del pre entrenado se reutilizan y cuáles se reentrenan/ajustan	8 h	Alumno	0 %
Sprint 7	HU7	Diseñar y documentar el contrato de <code>get_profile(user)</code> (esquema de entrada/salida)	6 h	Alumno	0 %
Sprint 7	HU7	Diseñar y documentar el contrato de <code>recommend(context)</code> (esquema de entrada/salida)	6 h	Alumno	0 %
Sprint 7	Contingencia	Buffer para desvíos del sprint	12 h	Alumno	0 %
Sprint 7	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %
Sprint 8	HU6	Ajustar el modelo dedicado a partir del pre entrenado (fine-tuning / transfer learning) sobre el dataset acotado	16 h	Alumno	0 %
Sprint 8	HU6	Entrenar un modelo de referencia desde cero sobre el mismo dataset acotado, para tener con qué comparar	12 h	Alumno	0 %
Sprint 8	HU6	Comparar las métricas de calidad entre el modelo dedicado y el modelo entrenado desde cero, y documentar la diferencia	8 h	Alumno	0 %
Sprint 8	Documentación	Redactar el capítulo de transfer learning	14 h	Alumno	0 %
Sprint 8	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %
Sprint 9	HU6	Validar que el proceso de ajuste es reproducible sobre el mismo dataset acotado	6 h	Alumno	0 %
Sprint 9	HU7	Implementar el endpoint <code>get_profile(user)</code> sobre el perfilador	8 h	Alumno	0 %
Sprint 9	HU7	Implementar el endpoint <code>recommend(context)</code> sobre el recomendador	8 h	Alumno	0 %
Sprint 9	HU7	Definir una estrategia de versionado del contrato ante cambios internos del motor	6 h	Alumno	0 %

Sprint	HU o fase	Tarea	Horas	Responsable	Avance
Sprint 9	HU8	Diseñar el flujo conversacional básico de la prueba de concepto, que incluye saludo, búsqueda, recomendación y cierre	6 h	Alumno	0 %
Sprint 9	Documentación	Redactar el capítulo de API y prueba de concepto	8 h	Alumno	0 %
Sprint 9	Documentación	Redactar las conclusiones de la memoria	8 h	Alumno	0 %
Sprint 9	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %
Sprint 10	HU7	Probar ambos endpoints de punta a punta, midiendo tiempos de respuesta y formatos, y documentar los resultados	6 h	Alumno	0 %
Sprint 10	HU8	Implementar el agente orquestador sobre la API de Claude, con las tools <code>get_profile/recommend</code> definidas	12 h	Alumno	0 %
Sprint 10	HU8	Integrar el agente con la API del motor (llamadas reales a <code>get_profile/recommend</code>)	8 h	Alumno	0 %
Sprint 10	HU8	Definir escenarios de prueba simulados que cubran un usuario recurrente, un usuario nuevo o cold-start, y un ítem sin metadata	6 h	Alumno	0 %
Sprint 10	HU8	Ejecutar y registrar al menos un ejemplo de conversación de punta a punta (log o transcripción)	4 h	Alumno	0 %
Sprint 10	HU8	Documentar cómo la prueba de concepto maneja los casos límite identificados	4 h	Alumno	0 %
Sprint 10	Defensa	Preparar la exposición y la defensa	10 h	Alumno	0 %
Sprint 10	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	Alumno	0 %

Cuadro 2. Planificación de sprints con tareas técnicas y no técnicas. Total estimado: 600 h.

La tabla 3 resume las fechas y la carga horaria de cada sprint.

El Sprint 10 finaliza a comienzos de marzo de 2027. Ese margen previo a la defensa, prevista para abril de 2027, se reserva para la revisión final de la memoria y para acordar la fecha de la exposición.

Cuadro 3. Resumen de la carga horaria por sprint.

Sprint	Fechas	Técnicas	No técnicas	Total
Sprint 0	25/08/2026 a 13/10/2026	0 h	60 h	60 h
Sprint 1	14/10/2026 a 27/10/2026	34 h	20 h	54 h
Sprint 2	28/10/2026 a 10/11/2026	38 h	16 h	54 h
Sprint 3	11/11/2026 a 24/11/2026	30 h	24 h	54 h
Sprint 4	25/11/2026 a 08/12/2026	32 h	22 h	54 h
Sprint 5	09/12/2026 a 22/12/2026	34 h	20 h	54 h
Sprint 6	23/12/2026 a 05/01/2027	38 h	16 h	54 h
Sprint 7	06/01/2027 a 19/01/2027	38 h	16 h	54 h
Sprint 8	20/01/2027 a 02/02/2027	36 h	18 h	54 h
Sprint 9	03/02/2027 a 16/02/2027	34 h	20 h	54 h
Sprint 10	17/02/2027 a 02/03/2027	40 h	14 h	54 h
Total		354 h	246 h	600 h

11. Diagrama de Gantt (sprints)

La figura 2 muestra la secuencia temporal de los sprints definidos en la sección anterior. Cada sprint ocupa una fila para sus tareas técnicas y otra para las no técnicas, que se distinguen por color. Entre ambas cubren las 600 horas del proyecto. El diagrama parte del inicio de la cursada, el 25 de agosto de 2026, y concluye con la defensa pública, prevista para abril de 2027.




Figura 2. Diagrama de Gantt. Las barras azules son tareas técnicas, las grises no técnicas y la naranja la defensa.

Como hitos principales se identifican la entrega del plan de proyecto el 13 de octubre de 2026, las sprint reviews al cierre de cada sprint y la defensa pública en abril de 2027.

12. Gobernanza de datos

Este análisis contempla el marco normativo y ético asociado al uso de los datos y al desarrollo de un sistema de recomendación basado en inteligencia artificial. Se divide en cumplimiento normativo y ética en el uso de inteligencia artificial.

12.1. Cumplimiento normativo

El proyecto se apoya en el dataset público Amazon Reviews²³, que contiene reseñas, calificaciones y metadata de productos. Esos datos describen el comportamiento de usuarios de una plataforma comercial, por lo que podrían alcanzar a normativas de protección de datos personales como el GDPR¹ o la Ley 25.326 de Protección de Datos Personales de Argentina². Según la documentación del dataset, los identificadores de usuario se encuentran anonimizados³. Aun así, el proyecto no intentará reidentificar a ningún usuario ni cruzar los datos con otras fuentes. Tampoco se almacenarán datos personales adicionales, ya que el sistema solo requiere el historial de reseñas y no información de contacto ni de identidad.

Las fuentes de datos son públicas y no propias. El dataset no tiene asociada una licencia puntual, aunque sus autores permiten su uso con fines académicos⁴. El código de procesamiento asociado se distribuye bajo licencia MIT⁵. El dataset acotado para el modelo dedicado todavía no fue identificado, por lo que se hará el mismo análisis de licencia al seleccionarlo y se documentará el resultado. Se aplicará el mismo criterio a las herramientas y a los servicios empleados. PostgreSQL y las librerías de código abierto de Python se utilizan bajo sus licencias permisivas. La API de Claude se emplea bajo los términos del proveedor y solo recibirá datos de prueba de la prueba de concepto, sin información personal.

Con estas medidas, el proyecto resulta legalmente viable. La trazabilidad de los datos se garantiza versionando los scripts de extracción y transformación, y registrando la versión del dataset y de los artefactos de los modelos que se derivan de él.

12.2. Ética en el uso de inteligencia artificial

Los datos de reseñas presentan sesgos que se trasladarán al modelo si no se controlan. Solo se observa a los usuarios que dejaron una reseña, por lo que el sistema puede favorecer a los más activos y a los productos populares. También hay un sesgo geográfico y cultural, ya que el dataset refleja principalmente a consumidores de una plataforma en particular. Además, los usuarios nuevos y los productos sin metadata quedan en desventaja por el problema de cold-start. Como consecuencia, las recomendaciones podrían reforzar hábitos de consumo ya existentes y reducir la diversidad de lo que se ofrece a cada persona.

¹Parlamento Europeo y Consejo de la Unión Europea (2016). Reglamento (UE) 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. <https://eur-lex.europa.eu/eli/reg/2016/679/oj>.

²Congreso de la Nación Argentina (2000). Ley 25.326 de Protección de los Datos Personales. <https://www.argentina.gob.ar/normativa/nacional/ley-25326-64790>.

³Hou, Y., Li, J., He, Z., Yan, A., Chen, X., & McAuley, J. (2024). Bridging Language and Items for Retrieval and Recommendation. *arXiv:2403.03952*. <https://arxiv.org/abs/2403.03952>.

⁴McAuley Lab (2024). Discusiones del dataset Amazon-Reviews-2023 en Hugging Face. <https://huggingface.co/datasets/McAuley-Lab/Amazon-Reviews-2023/discussions>.

⁵Hou, Y. (2024). AmazonReviews2023, licencia. <https://github.com/hyp1231/AmazonReviews2023/blob/main/LICENSE>.

El uso indebido de la solución también implica riesgos sociales. Un perfilador de comportamiento podría emplearse para manipular decisiones de compra, para inducir un consumo excesivo o para discriminar a ciertos segmentos de clientes. Además, un usuario final podría no saber que una recomendación proviene de un sistema automatizado.

Para mitigar estos riesgos se proponen las siguientes medidas.

- El score de confianza permite omitir recomendaciones poco fundadas.
- Cada recomendación incluye la traza de las señales que la originaron, lo que la vuelve explicable y auditable.
- El perfilado se limita a variables de comportamiento de compra y no incluye atributos sensibles como el género, la edad o el origen.
- La evaluación reportará el desempeño por segmento de usuario y no solo el promedio global.
- La documentación del proyecto declarará las limitaciones conocidas del sistema.

En términos generales, el proyecto se acota a una prueba de concepto sin uso productivo, lo que limita su impacto sobre personas reales. Si el motor se adoptara en un entorno comercial, deberían agregarse el consentimiento informado de los usuarios, la revisión humana de los resultados y una evaluación periódica de equidad y transparencia.

13. Gestión de riesgos

a) Identificación de los riesgos (al menos cinco) y estimación de sus consecuencias:

Riesgo 1: detallar el riesgo (riesgo es algo que si ocurre altera los planes previstos de forma negativa)

- Severidad (S): mientras más severo, más alto es el número (usar números del 1 al 10). Justificar el motivo por el cual se asigna determinado número de severidad (S).
- Probabilidad de ocurrencia (O): mientras más probable, más alto es el número (usar del 1 al 10). Justificar el motivo por el cual se asigna determinado número de (O).

Riesgo 2:

- Severidad (S): X.
Justificación...
- Ocurrencia (O): Y.
Justificación...

Riesgo 3:

- Severidad (S): X.
Justificación...
- Ocurrencia (O): Y.
Justificación...

b) Tabla de gestión de riesgos: (El RPN se calcula como $RPN=S \times O$)

Riesgo	S	O	RPN	S*	O*	RPN*

Criterio adoptado:

Se tomarán medidas de mitigación en los riesgos cuyos números de RPN sean mayores a...

Nota: los valores marcados con (*) en la tabla corresponden luego de haber aplicado la mitigación.

c) Plan de mitigación de los riesgos que originalmente excedían el RPN máximo establecido:

Riesgo 1: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).
Nueva asignación de S y O, con su respectiva justificación:

- Severidad (S*): mientras más severo, más alto es el número (usar números del 1 al 10). Justificar el motivo por el cual se asigna determinado número de severidad (S).
- Probabilidad de ocurrencia (O*): mientras más probable, más alto es el número (usar del 1 al 10). Justificar el motivo por el cual se asigna determinado número de (O).

Riesgo 2: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).

Riesgo 3: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).

14. Sprint Review

La revisión de sprint (*Sprint Review*) es una práctica fundamental en metodologías ágiles. Consiste en revisar y evaluar lo que se ha completado al finalizar un sprint. En esta instancia, se presentan los avances y se verifica si las funcionalidades cumplen con los criterios de aceptación establecidos. También se identifican entregables parciales y se consideran ajustes si es necesario.

Aunque el proyecto aún se encuentre en etapa de planificación, esta sección permite proyectar cómo se evaluarán las funcionalidades más importantes del backlog. Esta mirada anticipada favorece la planificación enfocada en valor y permite reflexionar sobre posibles obstáculos.

Objetivo: anticipar cómo se evaluará el avance del proyecto a medida que se desarrollen las funcionalidades, utilizando como base al menos cuatro historias de usuario del *Product Backlog*.

Seleccionar al menos 4 HU del Product Backlog. Para cada una, completar la siguiente tabla de revisión proyectada:

Formato sugerido:

HU seleccionada	Tareas asociadas	Entregable esperado	¿Cómo sabrás que está cumplida?	Observaciones o riesgos
HU1	Tarea 1	Módulo funcional	Cumple criterios de aceptación definidos	Falta validar con el tutor
	Tarea 2			
HU3	Tarea 1	Reporte generado	Exportación disponible y clara	Requiere datos reales
	Tarea 2			
HU5	Tarea 1	Panel de gestión	Roles diferenciados operativos	Riesgo en integración
	Tarea 2			
HU7	Tarea 1	Informe trimestral	PDF con gráficos y evolución	Puede faltar tiempo para ajustes
	Tarea 2			

15. Sprint Retrospective

La retrospectiva de sprint es una práctica orientada a la mejora continua. Al finalizar un sprint, el equipo (o el alumno, si trabaja de forma individual) reflexiona sobre lo que funcionó bien, lo que puede mejorarse y qué acciones concretas pueden implementarse para trabajar mejor en el futuro.

Durante la cursada se propuso el uso de la **Estrella de la Retrospectiva**, que organiza la reflexión en torno a cinco ejes:

- ¿Qué hacer más?
- ¿Qué hacer menos?
- ¿Qué mantener?
- ¿Qué empezar a hacer?
- ¿Qué dejar de hacer?

Aun en una etapa temprana, esta herramienta permite que el alumno planifique su forma de trabajar, identifique anticipadamente posibles dificultades y diseñe estrategias de organización personal.

Objetivo: reflexionar sobre las condiciones iniciales del proyecto, identificando fortalezas, posibles dificultades y estrategias de mejora, incluso antes del inicio del desarrollo.

Completar la siguiente tabla tomando como referencia los cinco ejes de la Estrella de la Retrospectiva (*Starfish* o estrella de mar). Esta instancia te ayudará a definir buenas prácticas

desde el inicio y prepararte para enfrentar el trabajo de forma organizada y flexible. Se deberá completar la tabla al menos para 3 sprints técnicos y 1 no técnico.

Formato sugerido:

Sprint tipo y N°	¿Qué hacer más?	¿Qué hacer menos?	¿Qué mantener?	¿Qué empezar a hacer?	¿Qué dejar de hacer?
Sprint técnico - 1	Validaciones continuas con el alumno	Cambios sin versión registrada	Pruebas con datos simulados	Documentar cambios propuestos	Ajustes sin análisis de impacto
Sprint técnico - 2	Verificar configuraciones en múltiples escenarios	Modificar parámetros sin guardar historial	Perfiles reutilizables	Usar logs para configuración	Repetir pruebas manuales innecesarias
Sprint técnico - 8	Comparar correlaciones con casos previos	Cambiar parámetros sin justificar	Revisión cruzada de métricas	Anotar configuraciones usadas	Trabajar sin respaldo de datos
Sprint no técnico - 12 (por ej.: “Defensa”)	Ensayos orales con feedback	Cambiar contenidos en la memoria	Material visual claro	Dividir la presentación por bloques	Agregar gráficos difíciles de explicar