



Sistema de recomendación para retail aumentado por transfer learning

Autor:

Lic. Matías Agustín Souto

Director:

Esp. Ing. Carlos Rodriguez (FIUBA)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 25 de agosto de 2026 y el 13 de octubre de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar	5
2. Identificación y análisis de los interesados	6
3. Propósito del proyecto	7
4. Alcance del proyecto	7
5. Supuestos del proyecto.	8
6. Product Backlog	8
7. Criterios de aceptación de historias de usuario	9
8. Fases de CRISP-DM	11
9. Desglose del trabajo en tareas	11
10. Planificación de Sprints	14
11. Diagrama de Gantt (sprints)	20
12. Gobernanza de datos	21
12.1 Cumplimiento normativo	21
12.2 Ética en el uso de inteligencia artificial	21
13. Gestión de riesgos	22
14. Sprint Review	23
15. Sprint Retrospective	24

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	25 de agosto de 2026
1	Se completa hasta el punto 5 inclusive	6 de septiembre de 2026
2	Se completa hasta el punto 9 inclusive	13 de septiembre de 2026
3	Se completa hasta el punto 12 inclusive	20 de septiembre de 2026
4	Se completa el plan	27 de septiembre de 2026

Acta de constitución del proyecto

Buenos Aires, 25 de agosto de 2026

Por medio de la presente se acuerda con el Lic. Matías Agustín Souto que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Sistema de recomendación para retail aumentado por transfer learning” y consistirá en la implementación del prototipo de un sistema de recomendación para compras online con miras a embeberlo en un flujo conversacional. El trabajo tendrá un presupuesto preliminar estimado de 600 horas y un costo, con fecha de inicio el 25 de agosto de 2026 y fecha de presentación pública en abril de 2027.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Equipo de IA Conversacional
NTT Data

Esp. Ing. Carlos Rodriguez
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El presente proyecto constituye una iniciativa personal del alumno, orientada a su propio crecimiento profesional dentro del área de inteligencia artificial conversacional. El autor se desempeña actualmente como ingeniero conversacional en NTT Data, una empresa de consultoría tecnológica y de telecomunicaciones, en la que se exploran diversas experiencias de compra conversacional que buscan replicar, dentro de una aplicación, la naturalidad de una interacción cara a cara en un comercio: el usuario inicia una sesión con un agente de voz o texto y solicita productos con la misma naturalidad con la que se lo pediría a una persona en una tienda. No se cuenta con financiamiento externo ni con acuerdos de confidencialidad o de propiedad intelectual asociados a este trabajo, ya que se trata de un desarrollo autónomo cuyos resultados son de autoría del alumno.

En el estado actual de la industria, se observa que la mayoría de las soluciones conversacionales para retail se limitan a actuar como buscadores de productos. En algunos casos llegan a incorporar un componente agéntico acotado (por ejemplo, agregar al carrito el producto ya identificado por el usuario). Sin embargo, estas soluciones no suelen incorporar un motor de recomendación robusto que profile al usuario y proponga proactivamente productos relevantes dentro del propio flujo conversacional, tal como lo haría un vendedor humano que reconoce a un cliente recurrente y anticipa sus preferencias.

El problema que se busca atender con este proyecto es, entonces, la falta de un componente de perfilado y recomendación que sea a la vez robusto y agnóstico a la plataforma conversacional que lo consume. La solución propuesta consiste en desarrollar un pipeline de perfilamiento-recomendación pensado como un servicio desacoplado del agente conversacional, expuesto a este último mediante una interfaz de herramientas llamables por el agente (*tools*) simple. Por ejemplo, `get_profile(user)` y `recommend(context)`. De esta forma, el mismo motor podría integrarse tanto a una experiencia de “compra sin clicks” completamente conversacional como a una aplicación de retail clásica, ya que las recomendaciones no dependen de cómo el usuario efectúa la compra sino de su perfil y comportamiento.

El motor por desarrollar se compone de dos módulos. El primero es un perfilador que clasifica a los usuarios en función de features RFM (Recencia, Frecuencia, Valor monetario) y de atributos de comportamiento adicionales. El segundo módulo del motor es un recomendador híbrido, que combina señales colaborativas, de contenido y de co-compra, y que produce un ranking de ítems a partir del perfil generado por el primer módulo. Un aspecto distintivo de la propuesta es que se aborda el recomendador como un problema de transfer learning: se entrena un modelo “pre entrenado” sobre un dataset extenso y público (Amazon Reviews’23) que permite acotar el universo de productos y perfiles a un conjunto de características y probabilidades de recomendación. Luego, se ajusta un modelo “dedicado”, derivado del anterior, sobre el conjunto de datos disponible para un caso de uso concreto, típicamente más escueto en volumen o en riqueza de atributos. La ganancia esperada de este enfoque es poder producir recomendaciones de mejor calidad con menos datos y menor costo de cómputo que si se entrenara un modelo desde cero para cada nuevo dominio.

En la figura 1 se presenta el diagrama en bloques del sistema. Se observa que el flujo conversacional queda contenido en un agente orquestador (para la prueba de concepto, una API simple sobre Claude), que interpreta el lenguaje natural del usuario y llama al pipeline de perfilado-recomendación a través de un contrato de interfaz estable. El “motor” agrupa al perfilador y al recomendador, cuyos resultados se persisten estado respecto de la conversación en curso (*stateful*). Como capa de persistencia se propone PostgreSQL, dada su capacidad

de almacenar tanto datos estructurados (reseñas, perfiles de usuario) como semiestructurados (metadata de ítems en formato JSONB, tabla de co-compra).




Figura 1. Diagrama del sistema.

El alcance de este trabajo se acota al diseño e implementación del sistema de perfilado-recomendación y de su API, sin abarcar el desarrollo del flujo conversacional completo. No obstante, se construirá una prueba de concepto que demuestre cómo un agente conversacional podría consumir dicha API en tiempo real. Entre los desafíos identificados a priori se destacan: el sesgo introducido por utilizar reseñas como proxy de compra (solo se observa al usuario cuando dejó una reseña), el problema de cold-start para usuarios e ítems nuevos, y la cobertura incompleta de metadata en parte del dataset, que se resolverá filtrando o marcando los ítems afectados según la estrategia de splitting estándar del dataset.

Se trata de un desarrollo desde cero que se llevará hasta el nivel de prueba de concepto. La innovación radica principalmente en el enfoque de transfer learning aplicado a la combinación perfilado-recomendación y en el diseño de una interfaz agnóstica al bot conversacional, lo que habilita su reutilización en distintos verticales de comercio.

2. Identificación y análisis de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Cliente	Equipo de IA Conversacional	NTT Data	Referente de producto
Responsable	Lic. Matías Agustín Souto	FIUBA	Alumno
Orientador	<i>Esp. Ing. Carlos Rodríguez</i>	<i>FIUBA</i>	Director del Trabajo Final
Usuario final	-	-	Consumidor de retail que compra vía canal conversacional

A continuación se detallan las principales características de cada interesado:

- Cliente: Equipo de IA Conversacional. Ofrece soluciones de compra conversacional a sus propios clientes. En este caso, de retail. Este interesado valora que el motor de perfilado-recomendación sea agnóstico al bot conversacional y a la vertical de comercio, de forma de poder reutilizarlo en distintas implementaciones para sus clientes.
- Responsable: el propio alumno, cursante de la Carrera de Especialización en Inteligencia Artificial de FIUBA, a cargo de la totalidad del diseño, desarrollo y documentación del proyecto.
- Orientador: a definir. Todavía no se encuentra asignado un director de Trabajo Final.
- Usuario final: es un consumidor genérico de una tienda de retail que interactúa con el agente conversacional para buscar y comprar productos. No se ha caracterizado un segmento específico de usuario, ya que el sistema está pensado para ser agnóstico al vertical de comercio.

3. Propósito del proyecto

Diseñar e implementar un sistema de perfilado y recomendación para retail, basado en un enfoque de transfer learning, que pueda integrarse como herramienta de un agente conversacional de compras. Se busca que el sistema profile a los usuarios a partir de features RFM y de comportamiento, y que genere recomendaciones híbridas de productos con una calidad aceptable incluso contando con pocos datos propios del cliente que lo adopte, aprovechando el conocimiento transferido desde un modelo pre entrenado sobre un dataset público y extenso. Se trata de una prueba de concepto con la que se pretende demostrar que es posible desacoplar la inteligencia de recomendación del canal conversacional específico. Este enfoque habilita su reutilización entre distintos bots y verticales de comercio. De esta manera, se espera avanzar en el desarrollo profesional del alumno dentro del área de inteligencia artificial conversacional.

4. Alcance del proyecto

El proyecto incluye:

- Diseño e implementación del módulo perfilador, basado en features RFM y atributos de comportamiento.
- Diseño e implementación del módulo recomendador híbrido (colaborativo + contenido + co-compra).
- Entrenamiento de un modelo pre entrenado sobre el dataset Amazon Reviews'23.
- Búsqueda y selección de un dataset más acotado, todavía no identificado, sobre el que ajustar un modelo “dedicado” vía transfer learning, para validar la hipótesis de mejores recomendaciones con menos datos.
- Exposición de los resultados vía una API con contrato estable (por ejemplo `get_profile`, `recommend`).
- Diseño del esquema de persistencia en PostgreSQL (reviews, perfiles de usuario, ítems, co-compra).
- Una prueba de concepto de un agente conversacional simple que se monte sobre la API sobre Claude para denotar el punta a punta.

El presente proyecto no incluye:

- El desarrollo del flujo conversacional completo ni de la interfaz de usuario final. Es decir, no es un desarrollo que se proponga entregar una solución conversacional punta a punta cerrada.
- La integración con un bot conversacional real de producción. Tampoco espera ser conectada a un bot específico.
- El despliegue en infraestructura productiva ni la operación continua del sistema.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- El dataset Amazon Reviews'23 es suficientemente representativo del comportamiento de compra como para entrenar un modelo pre entrenado útil, a pesar de estar compuesto por reseñas y no por transacciones directas.
- Que va a ser posible encontrar o construir un dataset más acotado, con menor volumen o riqueza de atributos, adecuado para validar el enfoque de transfer learning.
- Que la infraestructura de cómputo personal (o de bajo costo) disponible es suficiente para entrenar los modelos propuestos dentro de los plazos del proyecto.
- Que no van a existir cambios significativos en la disponibilidad o el formato del dataset público durante el desarrollo del proyecto.

6. Product Backlog

El Product Backlog se organiza en cuatro épicas, cada una con dos historias de usuario. El criterio para la asignación de story points fue la escala Fibonacci (1-2-3-5-8-13). Por lo tanto, solo se podrán asignar esos valores. Se pondera la complejidad técnica, el nivel de incertidumbre y la experiencia previa del alumno.

- Épica 1 — Perfilado de usuarios
 - HU1 (Prioridad: alta, 8 SP): como responsable del proyecto, quiero calcular las variables RFM (recencia, frecuencia, valor monetario) de cada usuario a partir de sus reseñas para poder clasificarlo según su comportamiento de consumo.
 - HU2 (Prioridad: media, 5 SP): como responsable del proyecto, quiero enriquecer el perfil RFM con atributos de comportamiento adicionales. Por ejemplo, categorías más frecuentes, o recencia por categoría para mejorar la calidad de la segmentación.
- Épica 2 — Motor de recomendación híbrido
 - HU3 (Prioridad: alta, 13 SP): como agente conversacional, quiero recibir un ranking de ítems que combine señales colaborativas, de contenido y de co-compra, para poder ofrecer recomendaciones más relevantes que con un solo enfoque aislado.
 - HU4 (Prioridad: media, 5 SP): como agente conversacional, quiero recibir un score de confianza junto con cada recomendación, para poder decidir cuándo mostrarla u ofrecer alternativas.
- Épica 3 — Transfer learning entre modelos
 - HU5 (Prioridad: alta, 13 SP): como responsable del proyecto, quiero entrenar un modelo sobre el dataset Amazon Reviews'23 para contar con una base amplia de productos y perfiles de usuario.
 - HU6 (Prioridad: alta, 13 SP): como responsable del proyecto, quiero ajustar un modelo dedicado a partir del pre entrenado sobre un dataset más acotado para validar que se pueden lograr buenas recomendaciones con menos datos.
- Épica 4 — Exposición vía API y prueba de concepto
 - HU7 (Prioridad: alta, 8 SP): como agente conversacional, quiero consultar `get_profile(user)` y `recommend(context)` a través de un contrato de API estable para poder recomendar productos sin conocer el detalle interno del motor.
 - HU8 (Prioridad: media, 8 SP): como usuario final, quiero recibir recomendaciones de productos dentro de una conversación de compra simulada para validar que el sistema funciona de punta a punta.

7. Criterios de aceptación de historias de usuario

- Épica 1
 - HU1:
 - (a) Para todo usuario con al menos una reseña, se calculan recencia, frecuencia y valor monetario sin valores nulos.

(b) Los tres valores se normalizan en una escala común y el cálculo es reproducible ante los mismos datos de entrada.

(c) El usuario queda asignado a un segmento RFM discreto y documentado. Por ejemplo, “cliente valioso”, “cliente en riesgo” o “cliente nuevo”.

El criterio de éxito será que al menos el 80 % de los usuarios con reseñas registradas queda correctamente segmentado, sin valores nulos ni indefinidos.

- HU2:

(a) El perfil incluye al menos dos atributos de comportamiento adicionales a RFM.

(b) Dichos atributos no duplican información ya cubierta por RFM.

(c) Se documenta el criterio de selección y el rango de valores esperado de cada atributo.

El criterio de éxito será que los atributos adicionales mejoren la separación entre segmentos respecto de usar solo RFM. Por ejemplo, mayor distancia o cohesión entre clústers.

- Épica 2

- HU3:

(a) Dado un perfil de usuario, se devuelve un ranking de al menos N ítems combinando las tres señales.

(b) Cada ítem recomendado incluye la traza de qué señal(es) contribuyeron a su score.

(c) El ranking no repite ítems ya comprados o reseñados por el usuario, salvo que se solicite explícitamente.

El criterio de éxito será que el ranking híbrido obtenga una métrica de calidad superior a la de cualquiera de las tres señales evaluadas de forma aislada. Por ejemplo, mejor precisión de clasificación (precision@10) o mejor NDCG@10.

- HU4:

(a) Cada recomendación devuelta incluye un score de confianza numérico en un rango definido. Un buen rango es $[0, 1]$ ya que está normalizado y facilita comparar recomendaciones entre sí.

(b) El score decrece de forma consistente ante menor evidencia disponible, como sería en el caso de un usuario nuevo.

(c) Existe un umbral configurable por debajo del que la recomendación puede omitirse.

El criterio de éxito será que aplicar el umbral de confianza reduzca la proporción de recomendaciones de baja relevancia sin descartar más del 20 % de las recomendaciones totales.

- Épica 3

- HU5:

(a) Se documenta la muestra de Amazon Reviews’23 utilizada (tamaño, categorías, período).

(b) Se reporta al menos una métrica de calidad sobre un conjunto de validación.

(c) El modelo y sus artefactos (pesos, features) quedan versionados y son reutilizables por el modelo dedicado.

El criterio de éxito será que el modelo pre entrenado supere a un baseline aleatorio o de popularidad en la métrica de calidad reportada sobre el conjunto de validación.

- HU6:

- (a) Se declara explícitamente el dataset acotado utilizado para el ajuste.
- (b) Se compara al menos una métrica de calidad entre el modelo dedicado y una alternativa entrenada desde cero.
- (c) El proceso de ajuste es reproducible sobre el mismo dataset acotado.

El criterio de éxito será que el modelo dedicado iguale o supere la métrica de calidad del modelo entrenado desde cero, usando el mismo dataset acotado, lo que validaría la ganancia del transfer learning.

- Épica 4

- HU7:

- (a) `get_profile(user)` responde en un formato de contrato documentado.
- (b) `recommend(context)` responde un ranking en formato documentado dentro de un tiempo inferior a 2 segundos en la prueba de concepto.
- (c) Ambos contratos se mantienen estables ante cambios internos del motor, y se versionan si cambian.

El criterio de éxito será que el 100% de las pruebas realizadas completen el ciclo `get_profile` → `recommend` sin errores y dentro del tiempo de respuesta acotado.

- HU8:

- (a) Un usuario simulado recibe al menos una recomendación dentro de una conversación con el agente.
- (b) El flujo de punta a punta queda documentado con al menos un ejemplo registrado.
- (c) Se documentan al menos dos casos límite, como un usuario nuevo o un ítem sin metadata, y cómo los maneja la prueba de concepto.

El criterio de éxito será que al menos una conversación simulada de punta a punta concluya con una recomendación mostrada al usuario, incluyendo el manejo correcto de los casos límite documentados.

8. Fases de CRISP-DM

1. Comprensión del negocio: el objetivo es perfilar usuarios y generar recomendaciones híbridas relevantes dentro de un flujo conversacional de retail. El valor agregado de la IA es habilitar una experiencia de vendedor proactivo. Las métricas de éxito son la calidad de las recomendaciones y evidencia de que el modelo dedicado supera a uno entrenado desde cero con menos datos.
2. Comprensión de los datos: el dataset principal es Amazon Reviews'23, que contiene reseñas, calificaciones y metadata de productos. Se releva su volumen, cobertura de metadata y el sesgo propio de basarse en reseñas, ya que solo se observa al usuario que dejó reseña.
3. Preparación de los datos: construcción de las features RFM por usuario, filtrado o marcado de ítems con metadata incompleta, y diseño del esquema de persistencia en PostgreSQL, que incluye reviews, perfiles, ítems en formato JSONB y una tabla de co-compra.
4. Modelado: el modelado se aborda como un problema híbrido, combinando perfilado mediante segmentación RFM y recomendación mediante enfoques colaborativo, de

contenido y de co-compra. Además, se aplicará transfer learning entre un modelo pre entrenado sobre un dataset extenso y un modelo dedicado ajustado sobre un dataset acotado.

5. Evaluación del modelo: se medirá la calidad de los rankings de recomendación y de la segmentación RFM, comparando el modelo dedicado contra una versión entrenada desde cero para validar la ganancia del transfer learning.
6. Despliegue del modelo: para esta prueba de concepto, el despliegue se limita a exponer el motor vía una API simple consumida por un agente conversacional de prueba (API sobre Claude), sin publicación en infraestructura productiva.

9. Desglose del trabajo en tareas

A partir de las historias de usuario definidas en la sección 6, se descompone el trabajo en tareas técnicas concretas y acotadas en el tiempo. El criterio de estimación considera la complejidad técnica, el nivel de incertidumbre, como la disponibilidad de un dataset acotado para el modelo dedicado, y la experiencia previa del alumno. La prioridad de cada tarea depende de su relevancia funcional y de si resulta bloqueante para otras tareas.

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU1	Realizar un análisis exploratorio de datos (EDA) sobre las reseñas del dataset, para entender distribución, calidad y cobertura por usuario	4 h	Alta
HU1	Extraer y limpiar la fecha de reseña, el rating o monto, y el producto de cada reseña por usuario	4 h	Alta
HU1	Calcular recencia y frecuencia por usuario	3 h	Alta
HU1	Calcular valor monetario (o proxy, dado que el dataset son reseñas) por usuario	3 h	Alta
HU1	Detectar y tratar outliers en las variables RFM (usuarios con actividad atípica)	4 h	Media
HU1	Normalizar las tres variables en una escala común y validar reproducibilidad	3 h	Alta
HU1	Definir umbrales/quantiles de segmentación RFM y documentar los segmentos resultantes	4 h	Alta
HU2	Explorar candidatos de atributos de comportamiento adicionales, como categorías frecuentes, recencia por categoría y diversidad de compra	3 h	Media
HU2	Diseñar el modelo de datos (esquema) del objeto “perfil de usuario”, integrando las variables RFM y los atributos seleccionados	4 h	Alta
HU2	Calcular los atributos seleccionados por usuario	4 h	Media
HU2	Validar, mediante un análisis de correlación y redundancia, que los nuevos atributos no dupliquen información ya cubierta por RFM	3 h	Media
HU2	Integrar los atributos calculados en el objeto perfil de usuario y documentar su rango esperado	3 h	Media

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU3	Realizar un EDA de ítems y de interacciones (compras/co-compra) para dimensionar sparsity y cobertura de metadata	4 h	Alta
HU3	Diseñar el esquema de salida del recomendador (ranking, score, señales que contribuyeron a cada ítem)	3 h	Alta
HU3	Explorar y entrenar un modelo de filtrado colaborativo que aprenda afinidades usuario-ítem a partir del historial de reseñas	8 h	Alta
HU3	Construir una señal de contenido, buscando ítems similares entre sí a partir de su categoría, sus atributos y su descripción	8 h	Alta
HU3	Construir una señal de co-compra, identificando qué ítems suelen comprarse juntos a partir de la tabla de co-compra	6 h	Alta
HU3	Diseñar y entrenar un modelo dedicado (ranker) que combine las tres señales en un único score de recomendación	8 h	Alta
HU3	Filtrar del ranking final los ítems ya comprados/reseñados por el usuario, salvo pedido explícito	2 h	Media
HU4	Definir qué señales de evidencia disponible se usan para estimar la confianza, como la cantidad de señales activas, la cobertura de datos o el cold-start	3 h	Media
HU4	Diseñar la fórmula o heurística de score de confianza en función de esas señales	3 h	Media
HU4	Implementar el cálculo del score y exponerlo junto con cada recomendación	3 h	Media
HU4	Definir y calibrar un umbral configurable por debajo del que la recomendación se omite o se reemplaza por un fallback	4 h	Media
HU5	Consolidar el perfilador (HU1/HU2) y el recomendador híbrido (HU3/HU4), entrenados sobre Amazon Reviews'23, como un único artefacto "modelo pre entrenado"	4 h	Alta
HU5	Evaluar el modelo pre entrenado de punta a punta (perfilado + recomendación) con una métrica de calidad sobre un conjunto de validación	5 h	Alta
HU5	Versionar y persistir los artefactos del modelo pre entrenado para que el modelo dedicado (HU6) pueda reutilizarlos	3 h	Media
HU6	Identificar o construir un dataset más acotado, con menor volumen o riqueza de atributos, adecuado para el ajuste	6 h	Alta
HU6	Definir el alcance del modelo dedicado: qué componentes del pre entrenado se reutilizan y cuáles se reentrenan/ajustan	4 h	Alta

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU6	Ajustar el modelo dedicado a partir del pre entrenado (fine-tuning / transfer learning) sobre el dataset acotado	8 h	Alta
HU6	Entrenar un modelo de referencia desde cero sobre el mismo dataset acotado, como línea base de comparación	6 h	Alta
HU6	Comparar las métricas de calidad entre el modelo dedicado y el modelo entrenado desde cero, y documentar la diferencia	4 h	Alta
HU6	Validar que el proceso de ajuste es reproducible sobre el mismo dataset acotado	3 h	Media
HU7	Diseñar y documentar el contrato de <code>get_profile(user)</code> (esquema de entrada/salida)	3 h	Alta
HU7	Diseñar y documentar el contrato de <code>recommend(context)</code> (esquema de entrada/salida)	3 h	Alta
HU7	Implementar el endpoint <code>get_profile(user)</code> sobre el perfilador	4 h	Alta
HU7	Implementar el endpoint <code>recommend(context)</code> sobre el recomendador	4 h	Alta
HU7	Definir una estrategia de versionado del contrato ante cambios internos del motor	3 h	Media
HU7	Probar ambos endpoints de punta a punta, midiendo tiempos de respuesta y formatos, y documentar los resultados	3 h	Alta
HU8	Diseñar el flujo conversacional básico de la prueba de concepto, que incluye saludo, búsqueda, recomendación y cierre	3 h	Media
HU8	Implementar el agente orquestador sobre la API de Claude, con las herramientas <code>get_profile/recommend</code> definidas	6 h	Media
HU8	Integrar el agente con la API del motor (llamadas reales a <code>get_profile/recommend</code>)	4 h	Media
HU8	Definir escenarios de prueba simulados que cubran un usuario recurrente, un usuario nuevo o cold-start, y un ítem sin metadata	3 h	Media
HU8	Ejecutar y registrar al menos un ejemplo de conversación de punta a punta (log o transcripción)	2 h	Media
HU8	Documentar la manera en que la prueba de concepto maneja los casos límite identificados	2 h	Media

Cuadro 1. Desglose de tareas por historia de usuario. Total estimado: 177 h.

10. Planificación de Sprints

La carga horaria total del proyecto se estima en 600 horas. Las tareas técnicas definidas en la sección 9 suman 177 horas. Para cubrir la incertidumbre propia de un trabajo individual y de

un dominio que el alumno explora por primera vez, esa estimación se duplicó al planificar los sprints, lo que da 354 horas técnicas. Las 246 horas restantes se destinan a tareas no técnicas, como la planificación, la redacción de la memoria, el seguimiento con el tutor, la preparación de la defensa y una reserva de contingencia.

El sprint 0 corresponde a la planificación y se extiende desde el inicio de la cursada hasta la entrega del plan. Los sprints 1 a 10 duran dos semanas cada uno y concentran entre 50 y 55 horas efectivas. Al ser un proyecto individual, el responsable de todas las tareas es el propio alumno. El porcentaje de avance se actualizará en cada revisión.

Sprint	HU o fase	Tarea	Horas	Avance
Sprint 0	Planificación	Definir el alcance del proyecto	8 h	0 %
Sprint 0	Planificación	Elaborar el cronograma	7 h	0 %
Sprint 0	Planificación	Redactar la descripción, los interesados, el propósito, el alcance y los supuestos del plan	8 h	0 %
Sprint 0	Planificación	Redactar el product backlog y los criterios de aceptación del plan	8 h	0 %
Sprint 0	Planificación	Redactar las fases de CRISP-DM y el desglose de tareas del plan	7 h	0 %
Sprint 0	Planificación	Redactar la planificación de sprints, el diagrama de Gantt, la gobernanza de datos y la gestión de riesgos del plan	7 h	0 %
Sprint 0	Planificación	Reunión con el tutor y el cliente	5 h	0 %
Sprint 0	Planificación	Ajustar las secciones 1 a 9 del plan según las devoluciones	5 h	0 %
Sprint 0	Planificación	Ajustar las secciones 10 a 15 del plan según las devoluciones	5 h	0 %
Sprint 1	HU1	Realizar un análisis exploratorio de datos (EDA) sobre las reseñas del dataset, para entender distribución, calidad y cobertura por usuario	8 h	0 %
Sprint 1	HU1	Extraer y limpiar la fecha de reseña, el rating o monto, y el producto de cada reseña por usuario	8 h	0 %
Sprint 1	HU1	Calcular recencia y frecuencia por usuario	6 h	0 %
Sprint 1	HU1	Calcular valor monetario (o proxy, dado que el dataset son reseñas) por usuario	6 h	0 %
Sprint 1	HU2	Explorar candidatos de atributos de comportamiento adicionales, como categorías frecuentes, recencia por categoría y diversidad de compra	6 h	0 %
Sprint 1	Documentación	Redactar la introducción de la memoria	8 h	0 %
Sprint 1	Documentación	Redactar el contexto de la memoria	8 h	0 %
Sprint 1	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 2	HU1	Detectar y tratar outliers en las variables RFM (usuarios con actividad atípica)	8 h	0 %

Sprint	HU o fase	Tarea	Horas	Avance
Sprint 2	HU1	Normalizar las tres variables en una escala común y validar reproducibilidad	6 h	0 %
Sprint 2	HU1	Definir umbrales/quantiles de segmentación RFM y documentar los segmentos resultantes	8 h	0 %
Sprint 2	HU2	Diseñar el modelo de datos (esquema) del objeto “perfil de usuario”, integrando las variables RFM y los atributos seleccionados	8 h	0 %
Sprint 2	HU2	Calcular los atributos seleccionados por usuario	8 h	0 %
Sprint 2	Documentación	Redactar la descripción del dataset en la memoria	6 h	0 %
Sprint 2	Documentación	Redactar el cálculo y la segmentación RFM en la memoria	6 h	0 %
Sprint 2	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 3	HU2	Validar, mediante un análisis de correlación y redundancia, que los nuevos atributos no dupliquen información ya cubierta por RFM	6 h	0 %
Sprint 3	HU2	Integrar los atributos calculados en el objeto perfil de usuario y documentar su rango esperado	6 h	0 %
Sprint 3	HU3	Realizar un EDA de ítems y de interacciones (compras/co-compra) para dimensionar sparsity y cobertura de metadata	8 h	0 %
Sprint 3	HU3	Diseñar el esquema de salida del recomendador (ranking, score, señales que contribuyeron a cada ítem)	6 h	0 %
Sprint 3	HU3	Filtrar del ranking final los ítems ya comprados/reseñados por el usuario, salvo pedido explícito	4 h	0 %
Sprint 3	Documentación	Redactar los atributos de comportamiento del perfil en la memoria	6 h	0 %
Sprint 3	Documentación	Redactar la integración y la validación del perfil de usuario en la memoria	6 h	0 %
Sprint 3	Contingencia	Buffer para desvíos del sprint	8 h	0 %
Sprint 3	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 4	HU3	Explorar enfoques de filtrado colaborativo y preparar la matriz de interacciones usuario-ítem	8 h	0 %
Sprint 4	HU3	Entrenar un modelo de filtrado colaborativo que aprenda afinidades usuario-ítem a partir del historial de reseñas	8 h	0 %

Sprint	HU o fase	Tarea	Horas	Avance
Sprint 4	HU3	Construir la representación de cada ítem a partir de su categoría, sus atributos y su descripción	8 h	0 %
Sprint 4	HU3	Calcular la similitud entre ítems y generar la señal de contenido	8 h	0 %
Sprint 4	Documentación	Documentar técnicamente la señal colaborativa	5 h	0 %
Sprint 4	Documentación	Documentar técnicamente la señal de contenido	5 h	0 %
Sprint 4	Contingencia	Buffer para desvíos del sprint	8 h	0 %
Sprint 4	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 5	HU3	Procesar la tabla de co-compra para identificar qué ítems suelen comprarse juntos	6 h	0 %
Sprint 5	HU3	Construir la señal de co-compra a partir de esos pares de ítems	6 h	0 %
Sprint 5	HU3	Diseñar un modelo dedicado (ranker) que combine las tres señales en un único score de recomendación	8 h	0 %
Sprint 5	HU3	Entrenar y validar el ranker	8 h	0 %
Sprint 5	HU4	Definir qué señales de evidencia disponible se usan para estimar la confianza, como la cantidad de señales activas, la cobertura de datos o el cold-start	6 h	0 %
Sprint 5	Documentación	Redactar las señales del recomendador híbrido en la memoria	8 h	0 %
Sprint 5	Documentación	Redactar el ranker y la combinación de señales en la memoria	8 h	0 %
Sprint 5	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 6	HU4	Diseñar la fórmula o heurística de score de confianza en función de esas señales	6 h	0 %
Sprint 6	HU4	Implementar el cálculo del score y exponerlo junto con cada recomendación	6 h	0 %
Sprint 6	HU4	Definir y calibrar un umbral configurable por debajo del que la recomendación se omite o se reemplaza por un fallback	8 h	0 %
Sprint 6	HU5	Consolidar el perfilador (HU1/HU2) y el recomendador híbrido (HU3/HU4), entrenados sobre Amazon Reviews'23, como un único artefacto "modelo pre entrenado"	8 h	0 %
Sprint 6	HU5	Definir la métrica de calidad y el conjunto de validación para evaluar el modelo pre entrenado	4 h	0 %

Sprint	HU o fase	Tarea	Horas	Avance
Sprint 6	HU5	Evaluar el modelo pre entrenado de punta a punta (perfilado + recomendación) sobre el conjunto de validación	6 h	0 %
Sprint 6	Documentación	Documentar el pre entrenamiento	6 h	0 %
Sprint 6	Documentación	Documentar la evaluación del modelo pre entrenado	6 h	0 %
Sprint 6	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 7	HU5	Versionar y persistir los artefactos del modelo pre entrenado para que el modelo dedicado (HU6) pueda reutilizarlos	6 h	0 %
Sprint 7	HU6	Relevar candidatos de datasets más acotados, con menor volumen o riqueza de atributos	6 h	0 %
Sprint 7	HU6	Seleccionar y preparar el dataset acotado para el ajuste	6 h	0 %
Sprint 7	HU6	Definir el alcance del modelo dedicado: qué componentes del pre entrenado se reutilizan y cuáles se reentrenan/ajustan	8 h	0 %
Sprint 7	HU7	Diseñar y documentar el contrato de <code>get_profile(user)</code> (esquema de entrada/salida)	6 h	0 %
Sprint 7	HU7	Diseñar y documentar el contrato de <code>recommend(context)</code> (esquema de entrada/salida)	6 h	0 %
Sprint 7	Contingencia	Buffer para desvíos de las tareas de HU5 y HU6	6 h	0 %
Sprint 7	Contingencia	Buffer para desvíos de las tareas de HU7	6 h	0 %
Sprint 7	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 8	HU6	Preparar el ajuste del modelo dedicado, fijando los componentes reutilizados y configurando los que se reentrenan	8 h	0 %
Sprint 8	HU6	Ajustar el modelo dedicado a partir del pre entrenado (fine-tuning / transfer learning) sobre el dataset acotado	8 h	0 %
Sprint 8	HU6	Entrenar un modelo de referencia desde cero sobre el mismo dataset acotado, como línea base de comparación	8 h	0 %
Sprint 8	HU6	Ajustar los hiperparámetros del modelo de referencia	4 h	0 %
Sprint 8	HU6	Comparar las métricas de calidad entre el modelo dedicado y el modelo entrenado desde cero, y documentar la diferencia	8 h	0 %
Sprint 8	Documentación	Redactar el enfoque y el ajuste del modelo dedicado en la memoria	7 h	0 %

Sprint	HU o fase	Tarea	Horas	Avance
Sprint 8	Documentación	Redactar la comparación contra el modelo de referencia en la memoria	7 h	0 %
Sprint 8	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 9	HU6	Validar que el proceso de ajuste es reproducible sobre el mismo dataset acotado	6 h	0 %
Sprint 9	HU7	Implementar el endpoint <code>get_profile(user)</code> sobre el perfilador	8 h	0 %
Sprint 9	HU7	Implementar el endpoint <code>recommend(context)</code> sobre el recomendador	8 h	0 %
Sprint 9	HU7	Definir una estrategia de versionado del contrato ante cambios internos del motor	6 h	0 %
Sprint 9	HU8	Diseñar el flujo conversacional básico de la prueba de concepto, que incluye saludo, búsqueda, recomendación y cierre	6 h	0 %
Sprint 9	Documentación	Redactar el capítulo de API y prueba de concepto	8 h	0 %
Sprint 9	Documentación	Redactar las conclusiones de la memoria	8 h	0 %
Sprint 9	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %
Sprint 10	HU7	Probar ambos endpoints de punta a punta, midiendo tiempos de respuesta y formatos, y documentar los resultados	6 h	0 %
Sprint 10	HU8	Implementar el agente orquestador sobre la API de Claude	6 h	0 %
Sprint 10	HU8	Definir las herramientas <code>get_profile/recommend</code> del agente	6 h	0 %
Sprint 10	HU8	Integrar el agente con la API del motor (llamadas reales a <code>get_profile/recommend</code>)	8 h	0 %
Sprint 10	HU8	Definir escenarios de prueba simulados que cubran un usuario recurrente, un usuario nuevo o cold-start, y un ítem sin metadata	6 h	0 %
Sprint 10	HU8	Ejecutar y registrar al menos un ejemplo de conversación de punta a punta (log o transcripción)	4 h	0 %
Sprint 10	HU8	Documentar la manera en que la prueba de concepto maneja los casos límite identificados	4 h	0 %
Sprint 10	Defensa	Preparar la presentación de la defensa	5 h	0 %
Sprint 10	Defensa	Ensayar la exposición	5 h	0 %
Sprint 10	Seguimiento	Sprint review, retrospectiva y reunión con el tutor	4 h	0 %

Cuadro 2. Planificación de sprints con tareas técnicas y no técnicas. Total estimado: 600 h.

La tabla 3 resume las fechas y la carga horaria de cada sprint.

Cuadro 3. Resumen de la carga horaria por sprint.

Sprint	Fechas	Técnicas	No técnicas	Total
Sprint 0	25/08/2026 a 13/10/2026	0 h	60 h	60 h
Sprint 1	14/10/2026 a 27/10/2026	34 h	20 h	54 h
Sprint 2	28/10/2026 a 10/11/2026	38 h	16 h	54 h
Sprint 3	11/11/2026 a 24/11/2026	30 h	24 h	54 h
Sprint 4	25/11/2026 a 08/12/2026	32 h	22 h	54 h
Sprint 5	09/12/2026 a 22/12/2026	34 h	20 h	54 h
Sprint 6	23/12/2026 a 05/01/2027	38 h	16 h	54 h
Sprint 7	06/01/2027 a 19/01/2027	38 h	16 h	54 h
Sprint 8	20/01/2027 a 02/02/2027	36 h	18 h	54 h
Sprint 9	03/02/2027 a 16/02/2027	34 h	20 h	54 h
Sprint 10	17/02/2027 a 02/03/2027	40 h	14 h	54 h
Total		354 h	246 h	600 h

El sprint 10 finaliza a comienzos de marzo de 2027. Ese margen previo a la defensa, prevista para abril de 2027, se reserva para la revisión final de la memoria y para acordar la fecha de la exposición.

11. Diagrama de Gantt (sprints)

La figura 2 muestra la secuencia temporal de los sprints definidos en la sección anterior. Cada sprint ocupa una fila para sus tareas técnicas y otra para las no técnicas, que se distinguen por color. Entre ambas cubren las 600 horas del proyecto. El diagrama parte del inicio de la cursada, el 25 de agosto de 2026, y concluye con la defensa pública, prevista para abril de 2027.

Como hitos principales se identifican la entrega del plan de proyecto el 13 de octubre de 2026, las sprint reviews al cierre de cada sprint y la defensa pública en abril de 2027.




Figura 2. Diagrama de Gantt. Las barras azules son tareas técnicas, las grises no técnicas y la naranja la defensa.

12. Gobernanza de datos

Este análisis contempla el marco normativo y ético asociado al uso de los datos y al desarrollo de un sistema de recomendación basado en inteligencia artificial. Se divide en cumplimiento normativo y ética en el uso de inteligencia artificial.

12.1. Cumplimiento normativo

El proyecto se apoya en el dataset público Amazon Reviews'23, que contiene reseñas, calificaciones y metadata de productos. Esos datos describen el comportamiento de usuarios de una plataforma comercial, por lo que podrían alcanzar a normativas de protección de datos personales como el GDPR¹ o la Ley 25.326 de Protección de Datos Personales de Argentina². Según sus autores, el dataset se limita a reseñas de productos visibles públicamente y a metadata de ítems, lo que minimiza los riesgos para la privacidad³. Aun así, el proyecto no intentará reidentificar a ningún usuario ni cruzar los datos con otras fuentes. Tampoco se almacenarán datos personales adicionales, ya que el sistema solo requiere el historial de reseñas y no información de contacto ni de identidad.

¹Parlamento Europeo y Consejo de la Unión Europea (2016). Reglamento (UE) 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. <https://eur-lex.europa.eu/eli/reg/2016/679/oj>.

²Congreso de la Nación Argentina (2000). Ley 25.326 de Protección de los Datos Personales. <https://www.argentina.gob.ar/normativa/nacional/ley-25326-64790>.

³Hou, Y., Li, J., He, Z., Yan, A., Chen, X., & McAuley, J. (2024). Bridging Language and Items for Retrieval and Recommendation. *arXiv:2403.03952*, apartado *Ethical considerations*. <https://arxiv.org/pdf/2403.03952>.

Las fuentes de datos son públicas y no propias. El dataset no tiene asociada una licencia puntual, aunque sus autores permiten su uso con fines académicos⁴. El código de procesamiento asociado se distribuye bajo licencia MIT⁵. El dataset acotado para el modelo dedicado todavía no fue identificado, por lo que se hará el mismo análisis de licencia al seleccionarlo y se documentará el resultado. Se aplicará el mismo criterio a las herramientas y a los servicios empleados. PostgreSQL y las librerías de código abierto de Python se utilizan bajo sus licencias permisivas. La API de Claude se emplea bajo los términos del proveedor y solo recibirá datos de prueba de la prueba de concepto, sin información personal.

Con estas medidas, el proyecto resulta legalmente viable. La trazabilidad de los datos se garantiza mediante el versionado de los scripts de extracción y transformación, y el registro de la versión del dataset y de los artefactos de los modelos que se derivan de él.

12.2. Ética en el uso de inteligencia artificial

Los datos de reseñas presentan sesgos que se trasladarán al modelo si no se controlan. Solo se observa a los usuarios que dejaron una reseña, por lo que el sistema puede favorecer a los más activos y a los productos populares. También hay un sesgo geográfico y cultural, ya que el dataset refleja principalmente a consumidores de una plataforma en particular. Además, los usuarios nuevos y los productos sin metadata quedan en desventaja por el problema de cold-start. Como consecuencia, las recomendaciones podrían reforzar hábitos de consumo ya existentes y reducir la diversidad de lo que se ofrece a cada persona.

El uso indebido de la solución también implica riesgos sociales. Un perfilador de comportamiento podría emplearse para manipular decisiones de compra, para inducir un consumo excesivo o para discriminar a ciertos segmentos de clientes. Además, un usuario final podría no saber que una recomendación proviene de un sistema automatizado.

Para mitigar estos riesgos se proponen las siguientes medidas.

- El score de confianza permite omitir recomendaciones poco fundadas.
- Cada recomendación incluye la traza de las señales que la originaron, lo que la vuelve explicable y auditable.
- El perfilado se limita a variables de comportamiento de compra y no incluye atributos sensibles como el género, la edad o el origen.
- La evaluación reportará el desempeño por segmento de usuario y no solo el promedio global.
- La documentación del proyecto declarará las limitaciones conocidas del sistema.

En términos generales, el proyecto se acota a una prueba de concepto sin uso productivo, lo que limita su impacto sobre personas reales. Si el motor se adoptara en un entorno comercial, deberían agregarse el consentimiento informado de los usuarios, la revisión humana de los resultados y una evaluación periódica de equidad y transparencia.

⁴McAuley Lab (2024). Discusiones del dataset Amazon-Reviews-2023 en Hugging Face. <https://huggingface.co/datasets/McAuley-Lab/Amazon-Reviews-2023/discussions>.

⁵Hou, Y. (2024). AmazonReviews2023, licencia. <https://github.com/hyp1231/AmazonReviews2023/blob/main/LICENSE>.

13. Gestión de riesgos

En esta sección se identifican los principales riesgos del proyecto, se estima su prioridad y se definen planes de mitigación para los más críticos. Cada riesgo se evalúa según su severidad (S) y su probabilidad de ocurrencia (O), ambas en una escala del 1 al 10. El producto de ambos valores da el número de prioridad del riesgo (RPN).

13.1. Identificación de los riesgos

Riesgo 1: no encontrar un dataset acotado adecuado para ajustar el modelo dedicado de HU6.

- Severidad (S): 8. Sin ese dataset no es posible validar el enfoque de transfer learning, que constituye la principal innovación del trabajo.
- Ocurrencia (O): 6. El dataset todavía no fue identificado y debe cumplir condiciones específicas de volumen, atributos y licencia.

Riesgo 2: que la infraestructura de cómputo disponible no alcance para entrenar sobre Amazon Reviews'23.

- Severidad (S): 5. El entrenamiento puede realizarse sobre una muestra del dataset, con una pérdida acotada de representatividad.
- Ocurrencia (O): 5. El dataset es muy voluminoso, aunque se distribuye por categorías, lo que facilita trabajar con subconjuntos.

Riesgo 3: desvíos en la carga horaria por compromisos laborales del alumno.

- Severidad (S): 6. Un desvío prolongado retrasaría las historias de usuario siguientes y podría comprometer la fecha de defensa.
- Ocurrencia (O): 6. Se trata de un proyecto individual que se desarrolla en paralelo a un empleo de tiempo completo.

Riesgo 4: que la escasez de interacciones y el cold-start degraden la calidad de las recomendaciones.

- Severidad (S): 6. Una calidad baja impediría cumplir el criterio de éxito de HU3, aunque no detiene el desarrollo del resto del sistema.
- Ocurrencia (O): 7. Es un problema propio de los datos de reseñas, ya que la mayoría de los usuarios deja pocas reseñas y muchos ítems tienen poca actividad.

Riesgo 5: que el modelo dedicado no supere al modelo entrenado desde cero.

- Severidad (S): 7. El resultado no validaría la hipótesis principal del trabajo, aunque seguiría siendo un hallazgo documentable.
- Ocurrencia (O): 5. La ganancia del transfer learning depende de la similitud entre ambos dominios, que todavía no puede estimarse.

13.2. Tabla de gestión de riesgos

La tabla ?? resume la evaluación de cada riesgo antes y después de aplicar la mitigación.

Cuadro 4. Gestión de riesgos.

Riesgo	S	O	RPN	S*	O*	RPN*
1. No encontrar un dataset acotado adecuado	8	6	48	6	3	18
2. Cómputo insuficiente para entrenar sobre el dataset	5	5	25	-	-	-
3. Desvíos en la carga horaria	6	6	36	-	-	-
4. Escasez de interacciones y cold-start	6	7	42	4	6	24
5. El modelo dedicado no supera al entrenado desde cero	7	5	35	-	-	-

Criterio adoptado: se tomarán medidas de mitigación en los riesgos cuyo RPN sea mayor a 40. Los riesgos 2, 3 y 5 quedan por debajo del umbral y se revisarán en cada retrospectiva.

Nota: los valores marcados con (*) corresponden a la estimación posterior a la aplicación de la mitigación.

13.3. Plan de mitigación

Riesgo 1: se relevarán candidatos de manera anticipada con parte de la reserva de contingencia de los sprints 3 y 4, lo que reducirá la ocurrencia. Además, se definirá como alternativa un subconjunto reducido de una categoría de Amazon Reviews²³, con menos atributos, que simule el caso de un cliente con pocos datos propios, lo que reducirá la severidad.

- Severidad (S*): 6. La alternativa permite validar el enfoque aunque no aparezca un dataset independiente, si bien con un caso de uso menos realista.
- Ocurrencia (O*): 3. La búsqueda comienza cuatro sprints antes de lo previsto, lo que deja margen para evaluar otras opciones.

Riesgo 4: se filtrarán para el entrenamiento los usuarios y los ítems con un mínimo de interacciones, lo que reducirá la ocurrencia. Además, se incorporará un fallback basado en popularidad para los usuarios nuevos y se usará el score de confianza de HU4 para omitir las recomendaciones con poca evidencia, lo que reducirá la severidad.

- Severidad (S*): 4. Aunque el problema ocurra, el sistema evita mostrar recomendaciones poco fundadas.
- Ocurrencia (O*): 6. El filtrado atenúa la dispersión en el entrenamiento, pero no la elimina, porque es propia de los datos de reseñas.

14. Sprint Review

Al cierre de cada sprint se realizará una revisión en la que el alumno presentará al tutor los avances y verificará si las funcionalidades cumplen con los criterios de aceptación de la sección 7.

Aunque el proyecto todavía se encuentra en etapa de planificación, esta sección proyecta cómo se evaluarán cuatro historias de usuario representativas del backlog. Se eligieron HU1, HU3, HU5 y HU7 porque cubren el perfilado, la recomendación, el pre entrenamiento y la exposición vía API, que son los componentes principales del sistema.

HU	Tareas asociadas	Entregable esperado	¿Cómo se sabrá que está cumplida?	Observaciones o riesgos
HU1	Análisis exploratorio de las reseñas, extracción y limpieza de los datos, cálculo de recencia, frecuencia y valor monetario, tratamiento de outliers, normalización y definición de los umbrales de segmentación.	Módulo de perfilado que asigna a cada usuario un segmento RFM documentado.	Se cumplen los criterios de aceptación de HU1 y al menos el 80 % de los usuarios con reseñas queda segmentado sin valores nulos.	El valor monetario se estima mediante un proxy, porque el dataset contiene reseñas y no transacciones.
HU3	Análisis exploratorio de ítems e interacciones, diseño del esquema de salida, construcción de las señales colaborativa, de contenido y de co-compra, entrenamiento del ranker y filtrado de ítems ya comprados.	Recomendador híbrido que devuelve un ranking de ítems con la traza de las señales que lo originaron.	El ranking híbrido supera a cada señal aislada en precision@10 o NDCG@10 y no repite ítems ya comprados.	Es la historia de mayor carga del backlog. La escasez de interacciones y el cold-start pueden afectar la calidad del ranking.
HU5	Consolidación del perfilador y del recomendador en un único artefacto, definición de la métrica y del conjunto de validación, evaluación de punta a punta y versionado de los artefactos.	Modelo pre entrenado sobre Amazon Reviews'23, versionado y acompañado de un reporte de evaluación.	El modelo supera a un baseline aleatorio o de popularidad en el conjunto de validación y sus artefactos pueden reutilizarse en HU6.	El volumen del dataset puede exceder el cómputo disponible, por lo que puede ser necesario trabajar sobre una muestra por categorías.
HU7	Diseño de los contratos de <code>get_profile</code> y <code>recommend</code> , implementación de ambos endpoints, definición de la estrategia de versionado y pruebas de punta a punta.	API con dos endpoints documentados y versionados.	El 100 % de las pruebas completa el ciclo <code>get_profile</code> → <code>recommend</code> sin errores y <code>recommend</code> responde en menos de 2 segundos.	El tiempo de respuesta depende del tamaño del modelo. Si se excede el límite, se evaluará precalcular parte de los rankings.

Cuadro 5. Revisión proyectada de las historias de usuario seleccionadas.

15. Sprint Retrospective

Como el desarrollo todavía no comenzó, la tabla ?? anticipa la retrospectiva de tres sprints técnicos y uno no técnico. Se eligieron el sprint 1, que corresponde al primer contacto con el dataset, el sprint 4, que concentra el entrenamiento de las señales del recomendador, el sprint 8, en el que se ejecuta el transfer learning, y el sprint 10, que incluye la preparación de la defensa.

Sprint	¿Qué hacer más?	¿Qué hacer menos?	¿Qué mantener?	¿Qué empezar a hacer?	¿Qué dejar de hacer?
Sprint técnico 1	Explorar muestras reducidas antes de procesar el dataset completo.	Limpiezas manuales sin registrar.	El registro de las decisiones de limpieza.	Fijar semillas y versionar los scripts de extracción.	Postergar la redacción de la memoria hasta el cierre del sprint.
Sprint técnico 4	Comparar cada señal contra un baseline de popularidad.	Pruebas de hiper-parámetros sin registro.	El esquema de salida definido en el sprint 3.	Registrar cada experimento con su configuración y su métrica.	Entrenar sobre el dataset completo sin validar antes con una muestra.
Sprint técnico 8	Comparar el modelo dedicado y el de referencia sobre la misma partición de datos.	Ajustes que favorezcan a uno de los dos modelos en la comparación.	El versionado de los artefactos del modelo pre entrenado.	Documentar los resultados negativos como hallazgos del trabajo.	Cambiar el dataset acotado a mitad del experimento.
Sprint no técnico 10	Ensayos cronometrados de la exposición.	Agregados de contenido nuevo a la memoria.	Diagramas simples, como el de la figura 1.	Preparar respuestas a las preguntas previsibles sobre los resultados.	Modificar el prototipo en los días previos a la defensa.

Cuadro 6. Retrospectiva proyectada para tres sprints técnicos y uno no técnico.